

星云知识库助手 产品手册

版本 1.0 | 适用于企业知识库问答、PDF 文档解析与大模型应用测试

1. 产品概述

星云知识库助手是一款面向企业内部知识管理场景的智能问答产品。用户可以上传 PDF、Word、Markdown 等资料，系统会对文档进行切分、向量化和检索，并结合大语言模型生成自然、准确、可追溯的中文回答。

本手册用于功能演示和 PDF 加载测试。文档中的文字均为可复制文本，适合使用 PyPDFLoader、pdfplumber、pypdf 等工具验证中文抽取效果。

2. 适用场景

- 客服知识库：快速回答售前咨询、售后流程、退换货规则和常见问题。
- 研发文档检索：查询接口说明、部署步骤、故障排查记录和版本变更。
- 培训资料问答：帮助新员工理解制度、流程、产品卖点和操作规范。
- 合同与制度检索：从长文档中定位条款，并生成简洁摘要。

3. 快速开始

首次使用时，请确认管理员已经完成模型服务、向量数据库和文件存储配置。普通用户只需要登录系统、选择知识库并输入问题即可。

- 1. 登录控制台，进入「知识库管理」页面。
- 2. 点击「新建知识库」，填写名称、描述和可见范围。
- 3. 上传 PDF 文件，等待系统完成解析、切分和索引构建。
- 4. 进入「智能问答」页面，选择目标知识库后输入问题。
- 5. 查看模型回答，并根据引用来源核对原文内容。

4. 核心功能

功能	说明	推荐用途
文档解析	支持提取 PDF、Word、Markdown 中的正文内容	构建企业知识库
语义检索	根据问题含义召回相关片段，而不是只匹配关键词	提升问答命中率
上下文问答	结合历史对话理解追问、改写和补充问题	连续对话
来源引用	回答中可附带文档名称、页码和片段编号	结果核验
权限控制	按部门、角色或项目限制知识库访问范围	企业内部使用

5. 参数配置

管理员可以在环境变量或配置中心中调整以下参数。不同部署环境的参数名称可以略有差异，但建议保留清晰的命名和默认值。

参数名	默认值	说明
LLM_MODEL	gpt-4o-mini	用于生成回答的大模型名称
EMBEDDING_MODEL	text-embedding-3-small	用于文档向量化的嵌入模型
CHUNK_SIZE	800	文档切分后的单个片段长度
CHUNK_OVERLAP	120	相邻片段之间的重叠字符数
TOP_K	5	每次检索返回的候选片段数量
TEMPERATURE	0.7	控制回答的发散程度，数值越高越灵活

6. 使用建议

1. 上传文档前尽量保持标题层级清晰，避免扫描图片中没有 OCR 文本。
2. 提问时尽量说明业务背景，例如产品名称、版本号、客户类型或具体流程。
3. 对于关键结论，应点击来源引用并核对原文，避免只依赖模型生成内容。
4. 当回答不完整时，可以继续追问「请展开第二点」或「请列出具体步骤」。

7. 常见问题

问：为什么上传 PDF 后没有检索结果？

答：请确认 PDF 中包含可复制文本。如果 PDF 是扫描件，需要先执行 OCR 识别，再重新上传。

问：为什么模型回答与原文不一致？

答：可能是召回片段不足或提示词约束不够。建议提高 TOP_K，优化系统提示词，并启用来源引用核验。

问：是否支持多轮对话？

答：支持。系统会把历史消息传入模型，模型可以理解上一轮问题和回答中的上下文。

问：如何保护内部资料？

答：建议启用访问权限、审计日志、私有化模型或企业级 API 网关，并限制敏感知识库的访问范围。

8. 测试用问题

1. 星云知识库助手适合哪些业务场景？
2. 文档解析功能支持什么类型的资料？
3. 如果 PDF 是扫描件，应该如何处理？
4. 请总结本产品的核心功能。
5. 请列出管理员可以配置的关键参数。

文档结束。此 PDF 专为中文文本抽取、分页读取、知识库加载和问答链路测试而创建。